KOBRA: 대한민국 국지 기상을 반영한 관측 기반 다차원 기상 데이터 플랫폼

KOBRA: A Korean Observation-Based Regional Atmospheric Data Platform

요 약

딥러닝 기상 예측 모델의 성능은 학습 데이터에 좌우되며, 국지 위험기상을 예측하려면 국지 기상을 담은 학습 데이터가 필요하다. 그러나 주로 사용되는 재분석 데이터 ERA5는 위경도 0.25°의 공간 해상도로 제공되어, 산지와 해안이 좁은 영역에 분포한 대한민국의 국지 기상을 표현하기 어렵다. 국내에서도 국지 기상 정보를 담은 데이터셋을 구축하려는 연구가 수행되었으나, 각 연구가 필요한 변수만으로 데이터셋을 개별 구축하여 변수·기간·보간 방법이 일관되지 않아 재사용과 결과 비교가 어렵다. 본 논문은 기상청의 지상·해양·고층 관측을 관측 지점 수, 기상 변수의 특성, 지형의 영향에 따라 서로 다른 보간 방법으로 격자화하여 2006~2025년의 5 km·500 m, 1시간 단위 104채널 다차원 데이터셋을 구축하고, 이를 필요한 범위만 추출할 수 있는 관측 기반 대한민국 기상 데이터 플랫폼 KOBRA(Korean Observation-Based Regional Atmospheric data platform)로 제공한다. 교차검증, ERA5와의 비교, 딥러닝 학습 실험을 통해 구축한 데이터셋이 관측소가 없는 위치의 값을 정확하게 추정하고, ERA5가 표현하지 못한 산지의 기온 차이를 나타내며, 별도의 전처리 없이 딥러닝 학습에 활용될 수 있음을 확인했다. KOBRA는 일관된 기준으로 구축된 관측 기반 데이터로 대한민국의 국지 기상을 연구할 수 있는 공통 기반을 제공하며, 새로운 변수와 관측으로 확장할 수 있다.

ABSTRACT

The performance of deep learning weather prediction models depends on their training data, and predicting local hazardous weather requires training data that capture local weather. However, ERA5, the reanalysis mainly used, has a spatial resolution of 0.25°, which makes it difficult to represent the local weather of Korea, where mountains and coasts lie within a small area. Studies in Korea have built datasets containing local weather information, but each built its own with only the variables it needed, so variables, periods, and interpolation methods are inconsistent, making reuse and comparison difficult. This paper grids surface, marine, and upper-air observations of the Korea Meteorological Administration with interpolation methods chosen by the number of observation sites, variable characteristics, and terrain influence into a 104-channel hourly dataset at 5 km and 500 m for 2006~2025, and provides it through KOBRA (Korean Observation-Based Regional Atmospheric data platform), from which users extract only the range they need. Cross-validation, comparison with ERA5, and a deep learning experiment confirmed that the dataset accurately estimates values at locations without stations, represents mountain temperature contrasts that ERA5 does not, and can be used for deep learning training without preprocessing. KOBRA provides a common basis for studying the local weather of Korea with consistently built observation-based data, and can be extended with new variables and observations.

키워드 : 기상 데이터, 날씨 변화 모델링, 시계열 모델, 딥러닝, 3D 데이터셋

Keywords: Weather data, Weather change modeling, Time series model, Deep learning, 3D datasets

Ⅰ. 서 론

기상 예측은 집중호우·폭염 등 위험기상에 대한 대응과 농업·에너지·교통 분야의 의사결정을 뒷받침하는 정보로, 주로 수치예보모델(NWP, Numerical Weather Prediction)에 기반하여 수행되어 왔다[1]. 수치예보모델은 대기를 3차원 격자로 이산화하고, 대기의 운동을 지배하는 물리 방정식을 수치적으로 풀어 미래의 대기 상태를 계산한다. 그러나 격자 간격보다 작은 규모의 구름과 대류는 직접 계산되지 않고 경험적 근사식인 모수화(parameterization)로 표현되므로, 집중호우나 돌풍과 같이 급변하는 국지 현상의 예측 정확도가 제한된다[2]. 이를 개선하기 위해서는 공간 해상도를 높여야 하나, 해상도가 높아질수록 계산 비용이 급격히 증가한다. 이러한 한계를 보완하기 위해 과거 기상 데이터로부터 시공간 변화 양상을 학습하여 예측을 수행하는 딥러닝 기반 기상 예측 모델이 제시되고 있다[3]. 딥러닝 모델의 학습에는 다수의 기상 변수가 동일한 격자와 시간축으로 정렬된 데이터셋이 요구되며, 주로 유럽중기예보센터(ECMWF, European Centre for Medium-Range Weather Forecasts)의 ERA5(ECMWF ReAnalysis 5)[4]가 활용된다. ERA5는 과거의 관측을 수치예보모델에 반영하여 전 지구의 대기 상태를 격자 단위로 재구성한 재분석 데이터이다.

다만 ERA5는 전 지구를 대상으로 하므로 위경도 0.25°(약 28 km)의 공간 해상도로 제공되며, 이는 산지와 해안이 좁은 영역에 복잡하게 분포하는 대한민국의 국지 기상을 표현하기에 충분하지 않다. 실제로 ERA5의 기온을 국내 관측소의 관측값과 비교하여, 산지와 해안에서 지형에 기인한 오차를 확인한 사례가 존재한다[5]. 따라서 대한민국의 국지 기상을 학습하기 위해서는 관측 기반 데이터셋이 요구된다. ERA5가 격자 단위의 평균값을 제공하는 것과 달리, 관측은 지점 단위의 실측값을 제공하므로 동일 격자 내 산지와 해안의 기상 차이를 구분할 수 있기 때문이다. 대한민국에는 약 668개소의 지상 관측소가 산지와 해안에 분포하여 이러한 국지적 차이를 기록하고 있다. 다만 관측값은 관측소가 위치한 지점에서만 얻어지므로, 이를 학습 데이터로 활용하기 위해서는 미관측 지점의 값을 추정하는 공간 보간이 필수적이다.

이에 국내에서도 관측을 공간 보간하여 데이터셋을 구축하고, 이를 딥러닝 모델의 학습에 활용한 연구가 수행되어 왔다[6-8]. 그러나 이러한 데이터셋은 각 연구의 목적에 따라 필요한 변수와 기간만을 선택하여 개별적으로 구축되었으며, 보간 기법과 구축 절차 또한 연구마다 상이했다. 격자값은 적용한 보간 기법에 따라 달라지며, 동일한 강수 관측에 서로 다른 보간 기법을 적용하였을 때 산악 유역의 월강수량이 약 10~20% 이상 차이를 보인 사례가 존재한다[9]. 이처럼 구축 방법이 표준화되지 않아, 기존 데이터셋은 다른 연구에서 재사용되기 어렵고 연구 결과 간의 비교 또한 제한된다. 또한 공간 해상도가 연구마다 고정되어 있어, 다른 해상도가 필요하면 데이터셋을 다시 구축해야 한다.

본 논문은 이러한 문제를 해결하기 위해, 기상청의 지상·해양·고층 관측 데이터를 수집하여 데이터셋으로 구축하고 이를 플랫폼 형태로 제공하는 관측 기반 대한민국 기상 데이터 플랫폼 KOBRA(Korean Observation-Based Regional Atmospheric data platform)를 제안한다. KOBRA는 관측의 수집부터 공간 보간까지를 하나의 체계로 정의하여, 동일한 관측과 보간 기법으로 연구에 필요한 공간 해상도의 데이터셋을 생성할 수 있도록 한다. 이 체계를 적용하여 2006~2025년의 관측을 기상 변수의 특성에 맞게 공간 보간하고, 5 km와 500 m 공간 해상도, 1시간 단위의 다차원 데이터셋을 구축한다. 구축한 데이터셋은 k-fold 교차검증으로 정확도를 평가하고, ERA5와 비교하여 국지 기상의 표현을 확인한다. 나아가 딥러닝 모델의 학습 실험을 통해 학습 데이터로서의 실용성을 검

그림 1. KOBRA의 데이터 파이프라인과 검증 실험 개요: (1) 관측 수집, (2) 데이터셋 구축, (3) 저장, (4) 추출, (5) 검증·활용

Fig. 1. Overview of the KOBRA data pipeline and validation experiments: (1) observation collection, (2) dataset construction, (3) storage, (4) extraction, (5) validation and application

증한다. 이를 통해 대한민국의 국지 기상을 반영한 학습 데이터를 일관된 기준으로 제공하고자 한다. 그림 1은 KOBRA의 데이터 파이프라인과 이를 검증한 실험의 개요이다. 본 논문의 기여는 다음과 같다.

첫째, 변수의 물리적 특성을 고려한 보간 기법을 적용하여 산지와 해안, 주변 해역과 상층 대기에 이르기까지 대한민국 관측망이 기록한 기상 특성을 반영한 학습 데이터를 구축함으로써, 대한민국의 국지 기상을 대상으로 하는 딥러닝 예측 연구에 기여한다.

둘째, 연구마다 개별적으로 구축되던 관측 기반 데이터셋을 대체할 수 있도록 단일 기준으로 구축된 공통 데이터셋을 제공함으로써, 서로 다른 연구의 결과를 동일한 데이터 기준에서 재현하고 비교할 수 있는 기반 마련에 기여한다.

셋째, 관측 데이터의 수집·격자화·추출 과정을 단일 플랫폼으로 통합하고 새로운 관측과 변수를 동일한 체계로 확장할 수 있는 구조를 제시함으로써, 관측 기반 기상 데이터의 지속적인 활용에 기여한다.

본 논문의 구성은 다음과 같다. 2장에서는 딥러닝 기반 기상 예측과 관측 기반 데이터셋에 관한 관련 연구를 소개하고, 3장에서는 데이터셋 및 플랫폼의 구축 방법을 기술한다. 4장에서는 데이터셋의 정확도와 국지 기상 표현, 학습 데이터로서의 실용성을 검증한다. 마지막으로 5장에서 결론과 한계, 향후 연구 방향을 제시한다.

Ⅱ. 관련 연구

2.1 딥러닝 기반 기상 예측 연구

딥러닝 기반 기상 예측은 전 지구를 대상으로 수일 앞의 기상을 예측하는 중기 예측에서 수치예보모델과 동등하거나 그 이상의 정확도를 달성했다. 대표적인 모델인 FourCastNet[10], Pangu-Weather[11], GraphCast[12]는 모두 ERA5로 학습하여 0.25°의 공간 해상도를 가진다. ERA5는 전 지구를 대상으로 하므로 대한민국 영역도 포함하지만, 전 지구를 하나의 격자 체계로 다루도록 구성되어 공간 해상도가 약 28 km로 넓다. 이 해상도로는 하나의 격자 안에 산지와 해안이 함께 존재하는 대한민국의 국지 기상을 표현하기 어려우므로, 국내에서는 국지 기상을 대상으로 한 딥러닝 예측 연구가 수행되어 왔다. 기상청 레이더 관측 데이터로 수 시간 이내의 강수를 예측한 연구[13, 14]와, 전국의 지상 관측소 데이터로 데이터셋을 구축하여 돌풍 예측 모델을 학습한 연구가 존재한다. 두 관측은 제공하는 정보가 다르다. 레이더 관측은 넓은 영역의 강수 분포를 격자 형태로 제공하지만, 관측 대상이 강수에 한정된다. 지상 관측은 기온·습도·바람·기압·강수 등 지표 부근의 기상 변수를 모두 제공하지만, 관측소가 위치한 지점의 값에 한정된다. 따라서 대한민국의 국지 기상을 여러 변수로 학습하는 데에는 지상 관측이 더 적합하며, 지점 단위의 관측을 격자 형태로 변환하기 위해서는 관측소 사이의 값을 주변 관측값으로부터 추정하는 공간 보간이 필요하다.

2.2 공간 보간 기법

공간 보간(spatial interpolation)은 관측 지점의 값으로부터 미관측 지점의 값을 주변 관측값의 가중합(weighted sum)으로 추정하는 기법이며, 역거리 가중법(inverse distance weighting)[15]과 크리깅(kriging)[16]이 대표적이다. 역거리 가중법은 거리의 역수를 가중치로 사용한다. 크리깅은 두 지점 사이의 거리에 따라 관측값이 얼마나 비슷한지를 분석하여 예측 오차를 최소화하는 가중치를 구하는 공간 통계 기법이다. 이 관계는 관측값들을 둘씩 짝지어 거리와 값의 차이를 계산한 베리오그램(variogram)으로 나타내며, 이를 수식으로 근사한 베리오그램 모델(variogram model)이 가중치 계산에 쓰인다.

크리깅은 추세(trend), 즉 기온이 북쪽으로 갈수록 그리고 높이 올라갈수록 낮아지는 것과 같은 값의 큰 흐름을 다루는 방식에 따라 세 종류로 나뉜다. 일반 크리깅(ordinary kriging)은 추세를 두지 않고 보간 범위 안에서 평균이 일정하다고 가정한다. 보편 크리깅(universal kriging)은 추세를 위치 좌표의 함수로 두어 함께 추정한다. 회귀 크리깅(regression kriging)은 추세를 고도처럼 모든 격자에서 값을 아는 보조 변수(covariate)로 설명하며, 관측값을 보조 변수에 회귀시켜 추세를 구하고 나머지인 잔차(residual)만 일반 크리깅으로 보간한 뒤 둘을 더한다[17].

역거리 가중법은 계산이 단순하고 빠르지만 관측값 사이의 공간 상관을 반영하지 못하고, 크리깅은 계산량이 많은 대신 정확도가 높다. 국내 관측을 대상으로 한 연강수량 보간 비교[18]와 최대순간풍속 보간 신뢰성 평가[19]에서 모두 크리깅이 가장 정확했으며, 후자에서는 값의 차이가 일정 거리 이후 더 커지지 않는다고 보는 spherical 모델이 베리오그램 모델로 가장 적합했다. 기온처럼 고도에 따라 변하는 변수는 거리와 고도를 함께 반영한 객관분석[20]과 고도 데이터를 보조 변수로 사용한 크리깅[21]에서 오차가 줄었다. 따라서 관측을 격자로 구축할 때는 변수의 특성과 지형에 맞는 보간 기법을 선택해야 한다.

2.3 기존 한계 및 접근 방법

국내에서도 이러한 보간 기법으로 관측 데이터를 격자

화한 데이터셋을 구축하고, 이를 기반으로 예측 모델을 개발하는 연구가 진행되었다. 그러나 이들 데이터셋은 각 연구의 목적에 맞추어 필요한 변수만을 대상으로 구축되었다. 국내에서 공개된 딥러닝 학습용 데이터셋인 KoMet[22]도 강수 예측을 위해 수치예보 출력과 강수 관측만을 포함하며, 기간도 2020~2021년 두 해의 여름철에 그친다. 이처럼 기존 데이터셋은 변수와 기간이 연구마다 달라, 대한민국의 국지 기상을 여러 변수와 긴 기간에 걸쳐 일관되게 학습할 수 있는 관측 기반 데이터셋이 필요하다.

이에 본 연구는 기상청의 지상·해양·고층 관측으로부터 여러 기상 변수를 동일한 격자와 시간축에 정렬한 데이터셋을 구축하고, 하나의 구축 체계 안에서 연구 목적에 맞는 다양한 공간 해상도로 생성할 수 있도록 한다. 격자화에 사용할 보간 기법은 대한민국의 관측 환경을 고려하여 선택한다. 대한민국은 관측소가 산지보다 평지에 많이 분포하고, 좁은 영역에 산지와 해안이 함께 있어 기상의 지역 편차가 크다. 이러한 조건에서는 관측소의 밀집을 보정하고 관측값 사이의 공간 상관을 반영하는 크리깅이 적합하다. 따라서 본 연구는 크리깅을 적용하며, 베리오그램 모델은 국내 평가에서 가장 적합했던 spherical 모델을 사용한다. 또한 관측소가 없는 산지의 값을 고도로부터 추정하기 위해, 기온과 같이 고도의 영향을 받는 변수에는 고도와 남북 좌표를 보조 변수로 하는 회귀 크리깅을 적용하고, 그 밖의 변수에는 일반 크리깅을 적용한다.

구축 방법과 산출 근거는 데이터셋과 함께 제공하고, 구축한 데이터셋의 정확도는 교차검증으로 평가한다. 또한 이를 플랫폼을 통해 제공하여 여러 연구가 같은 기준으로 구축된 데이터셋을 사용할 수 있게 한다.

Ⅲ. 데이터셋 및 플랫폼 구축 방법론

본 장에서는 대한민국 기상청의 관측 데이터를 수집하여 딥러닝 학습을 위한 격자 데이터셋으로 구축하고, 이를 플랫폼으로 제공하는 전체 과정을 설명한다. 먼저 기상청 API*를 통해 2006년 이후 대한민국 전국의 지상·해양·고층 관측 데이터를 수집하고, 결측과 이상값을 처리한다. 수집한 관측 데이터는 미관측 지점의 값을 추정하기 위해 각 기상 변수의 특성에 맞는 공간 보간을 적용하여, 5 km와 500 m의 공간 해상도와 1시간의 시간 해상도를 갖는 데이터셋으로 구축한다. 마지막으로 구축한 데이터셋을 사용자가 필요한 변수·기간·영역을 지정하여 추출할 수 있는 플랫폼을 통해 제공한다. 구축한 격자값의 정확도는 관측소 일부를 제외하고 그 지점의 값을 추정하여 관측값과 비교하는 방식으로 평가한다.

* https://apihub.kma.go.kr/

표 1. 수집한 기상청 관측의 종류별 생성 주기와 지점 수
Table 1. Reporting interval and number of stations by type of collected KMA observation

관측종류	관측 종류	생성 주기	지점 수
지상관측	종관기상관측	1시간	93
	방재기상관측	1시간	663
	황사관측	1시간	29
해양	부이·등표	1시간	67
고층	라디오존데	6시간	10

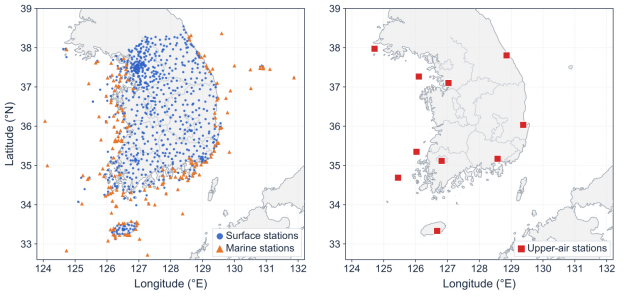

그림 2. 수집한 관측소의 분포 현황: (a) 지상·해양 관측소, (b) 고층 관측소
Fig. 2. Distribution of the collected stations: (a) surface and marine stations, (b) upper-air stations

3.1. 관측 데이터 수집 및 전처리

본 연구는 대한민국 기상청의 API를 통해 2006년부터 2025년까지의 지상·해양·고층 관측 데이터를 수집했다. 기상청 API는 관측 데이터 외에도 기상특보 등 다양한 기상 자료를 제공한다. 본 연구는 향후 이러한 자료를 구축한 데이터셋과 결합하여 활용할 수 있도록, 기상특보 자료가 제공되기 시작한 2006년을 수집 시작 시점으로 설정했다. 또한 KOBRA는 관측의 수집부터 공간 보간까지를 하나의 체계로 정의하므로, 같은 체계를 적용하면 관측별 제공 기간 내에서 2006년 이전으로도 데이터셋을 확장할 수 있다.

3.1.1 지상 관측

지상 관측은 지면 부근 및 지상에서의 기상 요소와 기상 현상을 관측하는 것을 의미하며, 크게 종관기상관측과 방재기상관측으로 구분된다. 종관기상관측은 고기압 및 저기압과 같은 넓은 범위의 날씨를 파악하기 위해 전국의 모든 관측소가 정해진 시각에 동시에 실시하는

지상 관측으로, 어제와 오늘의 날씨 변화를 파악하는 데 쓰인다. 전국에 총 105개 관측소가 있으며, 기온·강수·바람·기압과 같은 기본적인 기상 요소는 물론 사람이 직접 눈으로 확인해야 하는 구름 상태·시정·날씨 현상까지 기록한다. 이렇게 수집된 관측 데이터는 한반도 주변의 기압계를 파악하고 일기도를 작성하는 데 활용된다. 종관기상관측의 관측 데이터는 해당 지역의 날씨를 대표하는 값으로 사용되므로, 관측소는 주변보다 높은 지대에 위치하고 근처에 큰 건물이나 장애물이 없어야 하는 등의 설치 기준을 충족해야 한다. 종관기상관측의 가장 큰 특징은 전 세계가 관측 자료를 함께 공유한다는 점이다. 전 세계 모든 지역에서 6시간마다 정해진 시각에 관측을 실시하며, 수집된 자료는 세계기상기구를 통해 모아져 전 세계에 공유되고 각국의 일기 예보에 활용된다.

한편 방재기상관측은 기상 현상에 따른 자연재해를 예방하기 위해 수행되는 지상 관측이다. 이 105개 관측소만으로는 우리나라 전역의 기상 상태를 모두 파악하기 어렵기 때문에, 이러한 공백을 메우고 국지적인 기상 현상을 감지하기 위해 전국 554개 지점에 자동기상관측장비를 설치하여 운영한다. 방재기상관측은 종관기상관측과 달리 장비 설치에 특별한 조건이 없어 건물 옥상이나 도로 근처 등 다양한 장소에 설치되어 해당 지역의 날씨를 관측한다. 다만 무인으로 관측이 이루어지기 때문에 오차가 발생할 수 있고 주변 환경의 영향을 많이 받는다는 한계가 있다. 이로 인해 방재기상관측은 지역 날씨의 대푯값으로 보기 어렵고 전 세계에 공유되지 않으며, 우리나라에서 발생할 수 있는 갑작스러운 집중호우 등 극한 기상 상황에 대비하기 위한 용도로 주로 활용된다. 본 연구는 이러한 이유로 종관기상관측의 대표성과 방재기상관측의 조밀한 분포를 함께 활용하고자 두 관측을 모두 수집했다.

3.1.2 해양 관측

해양 관측은 해양 위의 대기와 해양의 상호작용으로 나타나는 기상 현상을 관측하는 것으로, 대한민국 기상청은 해양기상부이와 등표기상관측장비 등으로 관측한다. 해양기상부이는 해수면에서 해양 기상 현상을 각종 장비로 측정하고 그 값을 통신 장비로 전송하는 장비로, 풍향·풍속·기압·기온·습도와 파고·파주기·파향·수온을 관측한다. 등표기상관측장비는 등표나 관측탑 등의 해양 구조물에 기상관측장비를 설치하여 자료를 전송하는 장비로, 풍향·풍속·기압·기온·습도 등을 관측한다. 삼면이 바다인 대한민국에서는 해상의 기상이 해안 지역의 날씨에 직접 영향을 주지만, 바다 위에는 지상 관측소가 없어 지상 관측만으로는 연안 해역의 상태를 알 수 없다. 본 연구는 이러한 공백을 채우고 해안 지역의 국지 기상을 격자에 반영하기 위해 해양 관측을 수집했다.

3.1.3 고층 관측

고층 관측은 대기의 연직 구조를 파악하기 위해 고도별 기상 요소를 관측하는 것으로, 지상 관측과 함께 대기의 입체적인 움직임을 파악하여 예보에 필요한 기초 자료를 확보하는 데 목적이 있다. 대한민국 기상청은 라디오존데(Radiosonde)를 이용하여 관측한다. 라디오존데는 기압·기온·습도를 측정하는 센서와 측정값을 지상으로 전송하는 무선 송수신 장치를 탑재한 소형 기상측기로, 이를 기구에 매달아 띄우면 상승하면서 일정한 시간 간격으로 측정값을 지상으로 보낸다. 지상에서는 GPS 등으로 추적한 라디오존데의 이동 거리와 방향으로부터 풍속과 풍향을 산출한다. 고층 관측은 세계기상기구가 정한 공통 시각인 한국 표준시(KST, Korea Standard Time) 09시와 21시에 하루 2회 이루어지며, 필요에 따라 03시와 15시에도 추가로 관측한다. 국내 관측 지점은 기상청 8곳과 공군 2곳을 합쳐 10곳이다. 상공의 관측값은 높이 대신 기압으로 구분하며, 기압이 같은 지점을 이은 면을 기압면이라 한다. 850 hPa 기압면은 지상 약 1.5 km 높이에 해당하며, 한반도로 유입되는 하층 공기의 성질을 나타낸다. 500 hPa 기압면은 약 5.5 km 높이에 해당하며, 날씨 계통의 이동을 이끄는 중층의 흐름을 나타낸다. 한파·폭염·집중호우와 같은 지상의 국지 기상은 이러한 상층의 공기 유입과 흐름에 따라 결정되므로, 지상 관측만으로는 그 원인이 되는 대기 상태를 알 수 없다. 또한 ERA5로 학습하는 전 지구 딥러닝 모델도 지상 변수와 함께 여러 기압면의 변수를 입력으로 사용한다. 본 연구는 이러한 이유로 925~300 hPa의 다섯 기압면 관측을 수집했다.

표 1과 그림 2는 앞서 설명한 지상·해양·고층 관측의 지점 수와 위치를 나타낸다. 관측소는 시기에 따라 새로 설치되거나 폐지되므로, 그림 2는 2024년에 관측이 있었던 관측소를 기준으로 나타냈다. 지상 관측소는 수도권에 특히 밀집해 있고 내륙 산지보다 평지와 해안에 많으며, 해양 관측소는 서해안과 남해안을 따라 분포한다. 고층 관측소 10곳은 전국에 고르게 흩어져 있다.

3.1.4 전처리

결측은 기상청의 결측 표기 규칙에 따라 식별하여 결측값으로 변환했다. 또한 측정 오류로 물리적으로 나타날 수

없는 값이 기록된 관측은 제외했다. 제외 기준은 기상청 관측장비 표준규격의 측정 범위를 따르되, 실제 극값을 잃지 않도록 같거나 더 넓게 설정했으며, 표준규격에 기준이 없는 변수는 국내 관측 최고 기록을 포함하도록 설정했다.

3.2. 데이터셋 구축

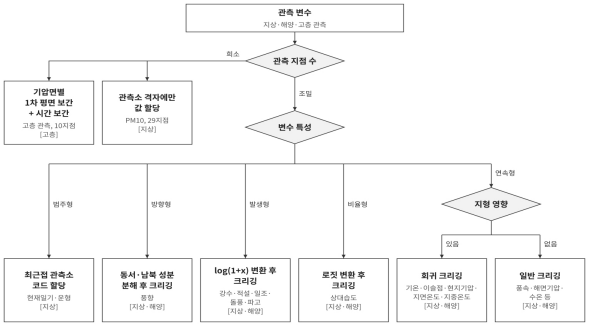

그림 3. 기상 변수별 공간 보간 방법의 선택 절차
Fig. 3. Procedure for selecting the spatial interpolation method for each weather variable

데이터셋은 대한민국 전역과 주변 해역을 포함하는 경도 약 122.7~132.1°, 위도 약 31.5~38.7°의 영역을 대상으로 한다. 이 영역 안에서 수집한 지상·해양·고층 관측의 모든 변수를 공간 보간하여, 변수마다 하나의 채널로 저장한 다차원 데이터셋을 구축하고자 한다.

공간 보간에는 앞서 선택한 크리깅을 적용했다. 다만 크리깅은 관측 지점 사이의 거리에 따른 값의 차이를 베리오그램으로 추정하여 가중치를 결정하므로, 변수의 관측 지점 수와 각 기상 변수의 특성에 따라 그대로 적용할 수 없는 경우가 있다. 베리오그램을 안정적으로 추정하기 위해서는 충분한 수의 관측 지점이 필요한데, 지상 관측은 한 시각에 수백 곳이 보고되지만 고층 관측은 10곳에 불과하다. 또한, 지상 관측 중에서도 황사를 관측하는 변수인 PM10(Particulate Matter 10 μm, 지름 10 μm 이하의 미세먼지 농도)은 기상청의 황사 관측 지점이 전국 29곳에 그쳐, 지상 관측의 다른 변수와 달리 베리오그램 추정이 불안정하다. 기상 변수의 특성에 따라 보간 결과가 왜곡되는 변수도 있다. 풍향과 같은 각도 변수는 산술 평균이 실제 방향을 나타내지 못하며, 강수와 같이 대부분의 시각이 0인 변수는 그대로 보간하면 드물게 발생한 큰 값이 주변으로 확산된다. 또한 기온과 같이 고도에 따라 변하는 변수는 거리만으로는 관측소가 없는 산지의 값을 추정할 수 없다. 본 연구는 이러한 이유로 변수를 관측 지점 수, 각 기상 변수의 특성, 지형의 영향에 따라 나누어 보간했으며, 변수의 분류와 분류별 보간 방법은 그림 3과 같다.

그림 3을 보면 먼저 변수의 관측 지점 수를 판단한다. 크리깅은 관측값으로부터 거리에 따른 값의 차이를 베리오그램으로 추정해야 하므로 관측 지점이 충분해야 한다. 지상·해양 관측은 수백 개의 관측소가 존재하지만, 고층 관측은 10곳, PM10은 29곳에 그쳐 크리깅을 적용할 수 없다.

이러한 이유로 고층 관측 데이터는 크리깅을 통한 공간 보간에 어려움이 존재한다. 다만 상층의 공기 유입과 흐름은 지상의 국지 기상에 영향을 주므로, 더 정확한 기상 예측을 위해서는 고층 관측 데이터를 데이터셋에 포함해야 한다. 이에 본 연구는 고층 관측에 기압면별 1차 평면 보간을 적용했다. 1차 평면 보간은 관측값에 가장 가깝게 맞춘 평면의 높이를 각 격자의 값으로 삼는 방법이다. 상층의 기온과 바람은 지표의 영향을 받지 않고 약 1,000 km 규모의 기압계에 따라 변하므로 [23], 그보다 훨씬 작은 한반도 영역에서는 한 방향으로 완만하게 변하는 분포가 대부분을 차지하여 평면으로 표현할 수 있다. 또한 평면은 세 개의 값으로 결정되므로 관측 지점이 10곳이어도 안정적으로 추정된다. 한편 데이터셋은 1시간 단위이지만 고층 관측은 09시와 21시 하루 2회만 이루어지므로 시간 보간도 필요하다. 두 관측 사이의 시각은 앞뒤 관측의 평면을 시간 간격에 비례하여 평균한 값으로 채웠다. 관측 사이의 변화에 대한 정보가 없으므로 가장 단순한 선형 변화를 가정한 것이며, 본 연구는 이 방식을 실험적으로 적용하고 일부 관측소의 03시·15시 보조 관측과 비교하여 타당성을 확인했다.

PM10은 황사 농도가 지점마다 크게 달라 관측소 사이의 값을 추정할 근거가 없으므로, 보간하지 않고 관측소가 위치한 격자에만 관측값을 할당한다.

다음으로 각 기상 변수의 특성에 따라 판단했다. 크리깅은 주변 관측값의 가중 평균으로 값을 추정하므로, 평균이 의미를 갖지 않거나 평균이 실제와 다른 값을 만드는 변수는 그대로 보간할 수 없다. 이에 해당하는 변수는 특성에 따라 다르게 처리했다. 현재일기·운형처럼 상태를 코드로 기록한 변수는 코드의 평균이 의미가 없으므로, 보간하지 않고 각 격자에 가장 가까운 관측소의 코드를 할당했다. 풍향은 각도여서 359°와 1°의 평균이 반대 방향인 180°가 되므로, 풍속과 결합하여 동서·남북 성분으로 분해한 뒤 성분별로 보간하고 다시 풍향으로 합쳤다. 강수·적설·일조·돌풍은 비가 오지 않는 시각처럼 대부분의 시각에 값이 0이고 드물게 큰 값이 나타나는데, 그대로 보간하면 그 큰 값이 주변 격자까지 넓게 퍼진다. 이들 변수는 큰 값의 영향을 줄이기 위해 값에 1을 더해 로그를 취하는 $\log(1+x)$ 변환을 거쳐 보간한 뒤 원래 값으로 되돌렸으며, 기상청 자료에서 발생하지 않은 시각의 값이 결측으로 기록되는 경우는 0으로 처리했다. 상대습도는 0~100% 사이의 값이지만 크리깅은 이 범위를 알지 못하므로, 그대로 보간하면 0보다 작거나 100%를 넘는 값이 나올 수 있다. 이를 막기 위해 0~100%의 비율을 상·하한이 없는 값으로 펴 주는 로짓 변환을 거쳐 보간을 진행했다.

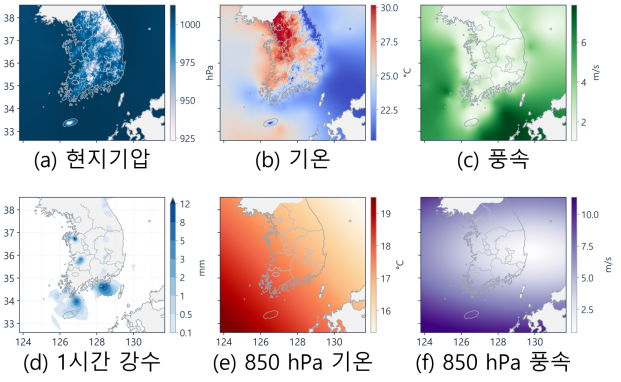

그림 4. KOBRA 데이터셋 시각화: (a) 현지기압, (b) 기온, (c) 풍속, (d) 1시간 강수, (e) 850 hPa 기온, (f) 850 hPa 풍속

Fig. 4. Visualization of the KOBRA dataset: (a) station pressure, (b) air temperature, (c) wind speed, (d) 1-h precipitation, (e) 850 hPa temperature, (f) 850 hPa wind speed

마지막으로 변수가 지형의 영향을 받는지를 판단했다. 기온·이슬점·지면온도·지중온도와 현지기압은 지형의 해발고도가 높을수록 값이 일정하게 낮아지는 추세가 있다. 그런데 관측소는 평지에 많고 산지에는 드물어, 거리만으로 보간하면 산지의 값이 주변 평지 관측값의 평균으로 채워져 실제보다 높게 추정된다. 따라서 이들 변수에는 관측소의 해발고도와 남북 좌표로 추세를 구해 관측값에서 제거하고, 남은 잔차만 일반 크리깅으로 보간한 뒤 각 격자의 해발고도로 계산한 추세를 더하는 회귀 크리깅을 적용했다. 남북 좌표는 같은 해발고도라도 위도에 따라 달라지는 기온을 반영한다. 풍속·해면기압처럼 지형의 영향이 작은 변수에는 일반 크리깅을 적용했다.

위 방법에 따라 크리깅을 매 시각 수행하여 데이터셋을 구축했다. 그림 4는 구축한 데이터셋의 예시로, 2024년 7월 15일 18시의 현지기압·기온·풍속·1시간 강수와 850 hPa 기온·풍속을 나타낸다. 현지기압과 기온에는 산맥의 형태가, 풍속에는 해상과 내륙의 차이가 나타난다.

데이터셋의 공간 해상도는 5 km와 500 m로 설정했다. 5 km는 기상청 단기예보가 제공되는 격자 간격과 같아, 구축한 데이터셋을 예보와 격자 단위로 맞추어 비교하고 함께 활용할 수 있다. 500 m는 산맥과 계곡 같은 지형의 형태를 표현할 수 있는 해상도로, 기상청이 제공하는 고해상도 격자 자료의 간격과도 같다. 추후 같은 절차로 이 밖의 다양한 해상도로도 구축할 예정이다. 이렇게 본 연구에서는 지상·해양 관측의 변수 73채널, 고층 관측의 기압면별 변수 31채널 등 총 104채널로 구성된 2006년부터 2025년까지의 다차원 데이터셋을 구축했다.

3.3. 플랫폼 구조 및 기능

이렇게 구축한 데이터셋은 웹 플랫폼을 통해 제공한다. 데이터셋은 20년 동안의 104채널을 1시간 단위로 담고 있으며, 연구마다 필요한 변수·기간·영역이 다르다. 따라서 ERA5를 배포하는 Climate Data Store[24]나 위성 관측을 배포하는 Google Earth Engine[25]과 같이, 사용자가 필요한 범위만 지정하여 추출하는 방식으로 제공한다.

플랫폼은 그림 5와 같이 관측 수집, 데이터셋 구축, 저장, 추출의 네 단계로 구성된다. 앞의 세 단계는 플랫폼 안에서 데이터셋을 만들고 갱신하는 과정이며, 사용자는 마지막 추출 단계를 웹 화면과 API로 이용한다.

이 네 단계는 데이터의 종류에 관계없이 동일한 절차로 수행되도록 체계화했다. 새로운 변수는 적용할 보간 방법을 지정하는 것만으로 동일한 절차에 따라 격자화되며, 새로운 기간의 관측은 월 단위로 수집부터 검사까지 동일한 단계를 거쳐 데이터셋에 반영된다. 새로운 종류의 관측에 대해서도 수집 단계만 추가하면 이후 단계를 동일하게 적용할 수 있다.

플랫폼에서는 그림 6과 같이 데이터셋·변수·기간·영역을 지정하고 지도에서 분포를 확인한 뒤 파일을 내려받으며, 그림 7과 같이 지도를 500 m 격자까지 확대하거나 항공 영상을 배경으로 세부 지역을 확인할 수 있다. 같은 조건은 API로도 요청할 수 있어 추출 과정을 코드로 재현할 수 있다. 분석 화면에서는 그림 8과 같이 변수 사이의 상관과 24절기별·행정구역별 분포를 확인하여 추출할 변수와 기간을 정할 수 있다.

Ⅳ. 실험 및 결과

구축한 데이터셋은 기상 예측뿐 아니라 농업·에너지·교통 등 기상의 영향을 받는 분야의 다양한 다운스트림 태스크(downstream task)에 활용될 수 있다. 또한 데이터셋은 격자 형태로 제공되므로, 합성곱 신경망과 같은 이미지 기반 딥러닝 모델의 입력으로 사용할 수 있다. 나아가 위성 영상과 같은 영상 자료, 예보문과 같은 텍스트 자료, 기상특보와 같은 위험기상 발생 자료 등 형태가 다른 데이터와 결합하여, 이들을 함께 학습하는 멀티모달 학습(multimodal learning)으로도 활용을 확장할 수 있다. 그러나 보간으로 추정한 값의 정확도는 변수와 지역에 따라 다르므로, 데이터셋이 모든 활용에서 같은 효과를 갖는 것은 아니다. 따라서 본 장의 실험은 데이터셋의 유효성을 검증하는 동시에, 연구의 목적에 따라 데이터셋이 적합한지 판단하는 기준을 제공하는 것을 목적으로 한다. 4.1절에서는 교차검증으로 변수별 정확도를 평가하고, 4.2절에서는 ERA5와 비교하여 고해상도 데이터셋이 효과를 보이는 지역을 확인하며, 4.3절에서

그림 5. 관측 수집, 데이터셋 구축, 저장, 추출 단계로 구성된 KOBRA의 시스템 구조

Fig. 5. System architecture of KOBRA consisting of observation collection, dataset construction, storage, and extraction stages

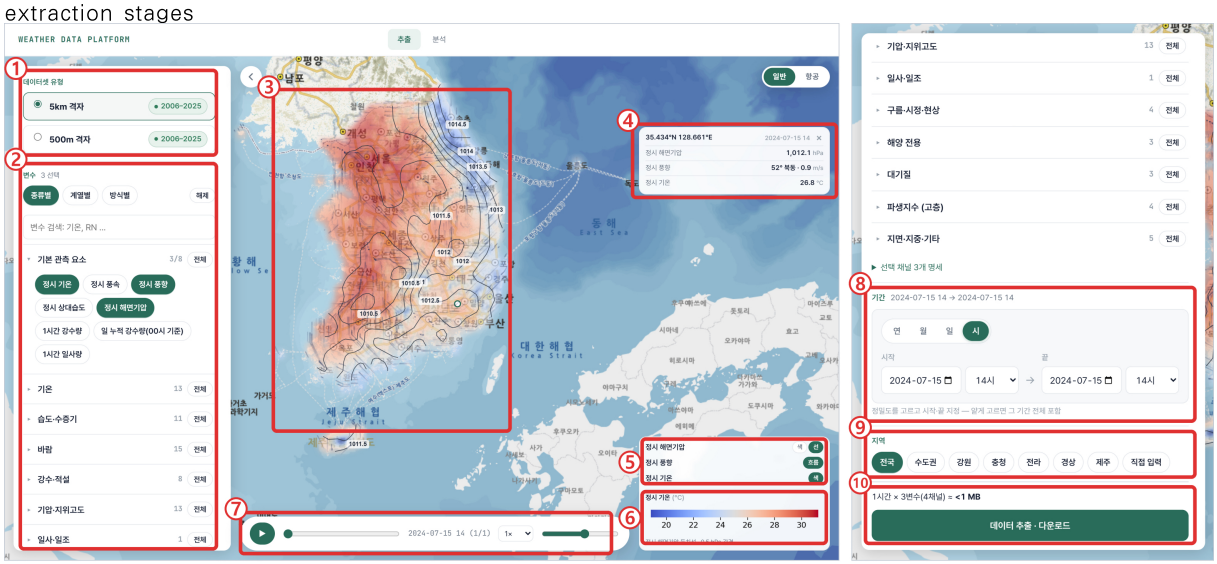

(a) (b)

그림 6. KOBRA의 데이터 조회·추출 화면: (a) 전체 화면(① 데이터셋 선택, ② 변수 선택, ③ 격자 지도, ④ 지점 값 조회, ⑤ 표시 변수 설정, ⑥ 색상 범례, ⑦ 시간 탐색), (b) 추출 조건 패널(⑧ 기간 선택, ⑨ 지역 선택, ⑩ 추출 실행)

Fig. 6. Data browsing and extraction interface of KOBRA: (a) full screen (① dataset selection, ② variable selection, ③ grid map, ④ point value query, ⑤ display variable settings, ⑥ color legend, ⑦ time navigation), (b) extraction condition panel (⑧ period selection, ⑨ region selection, ⑩ extraction execution)

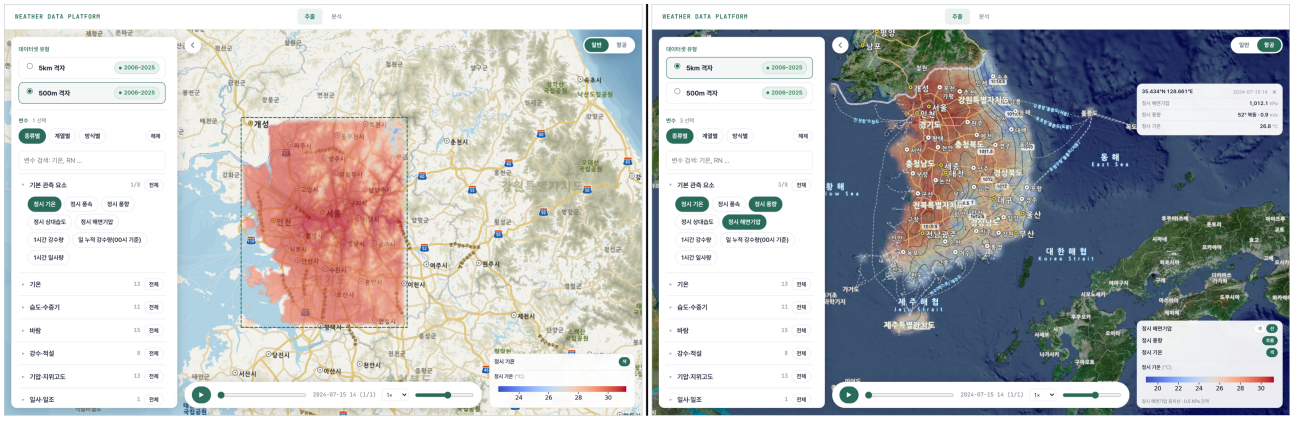

(a) (b)

그림 7. KOBRA의 기능: (a) 지정 영역 추출, (b) 항공 영상 뷰 전환

Fig. 7. Functions of KOBRA: (a) extraction of a specified area, (b) switching to the aerial-image view

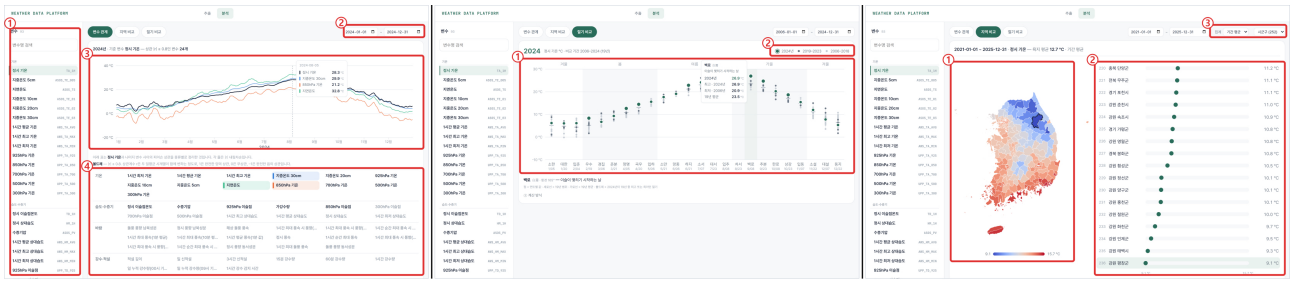

(a) (b) (c)

그림 8. KOBRA의 분석 화면: (a) 변수 관계(① 기준 변수 선택, ② 기간 선택, ③ 상관 변수 시계열, ④ 상관 변수 목록), (b) 24절기 비교(① 절기별 값, ② 비교 연도 선택), (c) 시군구 비교(① 시군구별 지도, ② 지역별 순위, ③ 집계 방식 선택)

Fig. 8. Analysis interface of KOBRA: (a) variable relations (① reference variable selection, ② period selection, ③ time series of correlated variables, ④ correlated variable list), (b) 24 solar terms comparison (① values by solar term, ② comparison year selection), (c) municipality comparison (① municipality map, ② regional ranking, ③ aggregation method selection)

는 대표적인 다운스트림 태스크인 단기 기상 예측에 데이터셋을 적용하여 별도의 가공 없이 학습 데이터로 활용할 수 있는지를 확인한다.

4.1. 데이터셋 검증 및 평가

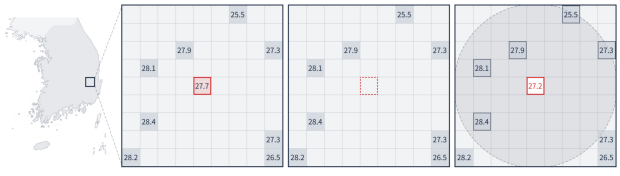

(a) (b) (c)

그림 9. 교차검증 절차: (a) 검증 관측소 선정, (b) 해당 관측값 제외, (c) 남은 관측소로 검증 위치의 값 추정

Fig. 9. Cross-validation procedure: (a) selection of a validation station, (b) removal of its observation, (c) estimation of the value at its location from the remaining stations

구축한 데이터셋의 격자 값은 대부분 미관측 지점에서 주변 관측소의 값으로 추정한 것이므로, 데이터셋의 정확도는 미관측 지점에서 평가해야 한다. 그러나 미관측 지점에는 비교할 관측값이 없다. 이에 관측소의 일부를 격자 구축에서 제외하여 미관측 지점과 같은 조건으로 만들고, 남은 관측소만으로 다시 구축한 격자에서 그 위치의 추정값을 실제 관측값과 비교했다. 제외된 관측소는 구축에 사용되지 않으므로, 이 차이는 미관측 지점에서 데이터셋이 갖는 오차에 해당한다. 다만 제외할 관측소를 한 번만 정하면 그 위치에서만 오차를 얻으므로, 관측소를 k개의 묶음으로 나누고 묶음을 하나씩 돌아가며 제외하는 k-fold 교차검증(k-fold cross-validation)[26]을 적용하여 모든 관측소 위치에서 오차를 얻었다. 그림 9는 이 과정을 나타낸 것이다. 본 연구에서는 k를 5로 설정하여 한 번에 관측소의 20%를 제외하고, 이를 다섯 번 반복했다.

검증 변수로는 딥러닝 기상 예측에 널리 활용되는 기온, 상대습도, 풍속, 1시간 강수를 사용했다. 오차는 평균절대오차(MAE, Mean Absolute Error)와 큰 오차에 더 큰 가중을 두는 평균제곱근오차(RMSE, Root Mean Square Error)로 평가했다. 다만 오차의 크기만으로는 그 정확도가 충분한지 판단하기 어려우므로, 가장 가까운 관측소의 값을 그대로 사용하는 최근접 이웃법(nearest neighbor)과 역거리 가중법으로도 같은 격자를 구축하여 오차를 비교했으며,

표 2. k-fold 교차검증(k=5)을 통한 공간 보간 기법별 추정 오차

Table 2. Estimation errors of each spatial interpolation method from k-fold cross-validation (k = 5)

변수	평가 지표	KOBRA	IDW	Nearest neighbor
기온 (°C)	RMSE	1.41	1.57	1.97
	MAE	0.98	1.08	1.33
상대습도 (%p)	RMSE	8.58	8.54	10.79
	MAE	6.00	6.06	7.48
풍속 (m/s)	RMSE	1.46	1.43	1.81
	MAE	0.95	0.96	1.20
1시간 강수 (mm)	RMSE	0.86	0.81	0.97
	MAE	0.10	0.10	0.12

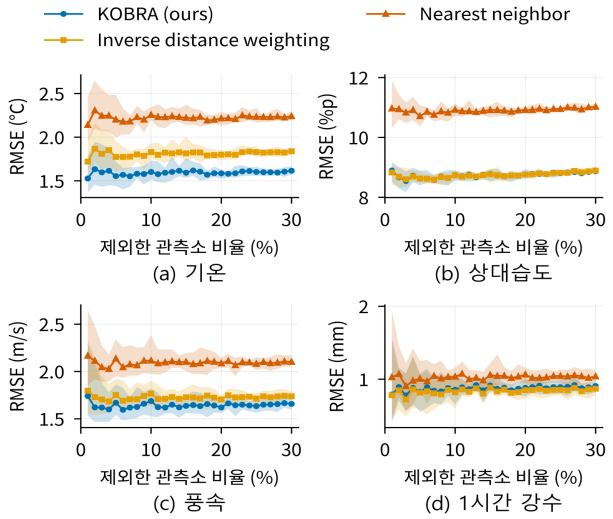

그림 10. 관측소 분포 밀도에 따른 공간 보간 기법별 평균제곱근오차: (a) 기온, (b) 상대습도, (c) 풍속, (d) 1시간 강수

Fig. 10. RMSE of each spatial interpolation method by station distribution density: (a) air temperature, (b) relative humidity, (c) wind speed, (d) 1-h precipitation

그 차이의 유의성은 같은 시각의 관측소를 하나의 블록으로 묶어 재추출하는 블록 부트스트랩(block bootstrap)의 95% 신뢰구간으로 검정했다.

표 2의 교차검증 결과에서 구축 데이터셋의 평균제곱근오차는 네 변수 모두 최근접 이웃법보다 낮아 기온 28%, 상대습도 21%, 풍속 19%, 1시간 강수 12% 감소했다. 역거리 가중법과 비교하면 기온의 평균제곱근오차가 1.41 °C로 역거리 가중법의 1.57 °C보다 10% 낮았으며, 해발고도가 높은 관측소일수록 그 차이가 커졌다. 이는 기온에 적용한 회귀 크리깅이 해발고도에 따른 기온 변화를 반영하기 때문이다. 반면 상대습도, 풍속, 1시간 강수에서는 두 방법의 차이가 6% 이내였다.

다만 표 2는 관측소의 20%를 제외한 조건의 결과이며, 실제 관측소의 밀도는 지역과 시기에 따라 다르다. 이에 제외하는 관측소의 비율을 1%부터 30%까지 1%씩 바꾸어, 관측소가 드문 조건에서도 정확도가 유지되는지 확인했다.

그림 10과 같이 제외 비율을 높여도 구축 데이터셋의 오차는 거의 증가하지 않아 기온의 평균제곱근오차는 1.53~1.63 °C에 머물렀으며, 최근접 이웃법보다 낮은 네 변수의 오차와 역거리 가중법보다 낮은 기온의 오차도 모든 비율에서 유지되었다. 즉 데이터셋의 정확도는 관측소의 수에 거의 의존하지 않으므로, 관측소가 드문 지역이나 시기에서도 같은 수준의 정확도를 기대할 수 있다.

이처럼 구축 데이터셋은 미관측 지점에서 최근접 이웃법보다 정확했으며, 그 정확도는 관측소의 밀도에 관계없이 일관되게 유지되었다. 변수별로는 기온이 역거리 가중법보다도 정확하여 지형의 영향을 받는 국지 기상 연구에 적합하다. 반면 상대습도, 풍속, 1시간 강수는 역거리 가중법과 비슷한 수준이므로, 이들 변수의 국지적 차이를 다루는 연구에서는 이를 고려해야 한다.

4.2. 국지 기상 표현 비교

표 3. 태백산맥 일대 관측소의 관측값과 ERA5·KOBRA 기온 비교(°C)

Table 3. Comparison of observed values at stations over the Taebaek Mountains with ERA5 and KOBRA air temperature (°C)

구분	홍천	서석	평창	대관령	성산	MAE	RMSE
관측	−7.5	−9.7	−10.8	−10.4	−6.5	-	-
ERA5	−8.4	−10.3	−6.9	−6.9	−6.9	1.86	2.42
KOBRA (Ours)	−8.1	−9.3	−9.3	−8.5	−5.4	1.12	1.26

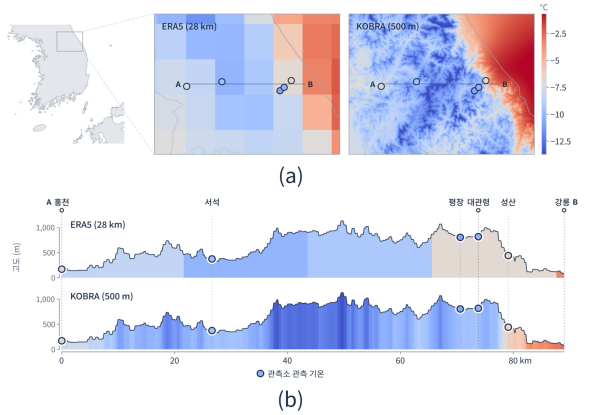

그림 11. 태백산맥 일대의 ERA5와 KOBRA 기온 비교: (a) 두 데이터셋의 영역별 기온 시각화, (b) 산맥 횡단면의 고도에 따른 데이터셋 기온과 관측소 기온 비교

Fig. 11. Comparison of ERA5 and KOBRA air temperature over the Taebaek Mountains: (a) visualization of temperature from both datasets over the area, (b) comparison of dataset and station temperatures by elevation along a cross-section of the mountains

ERA5는 공간 해상도가 0.25°이므로 하나의 격자 안에 산지와 해안이 함께 포함되며, 두 지역의 기온이 달라도 하나의 값으로 나타난다. 이에 구축 데이터셋이 이러한 격자 안의 기온 차이를 관측대로 나타내는지 확인했다.

그림 11과 표 3은 2023년 1월 25일 15시 태백산맥 일대의 기온 사례이다. ERA5는 이 일대를 몇 개의 격자 값으로 나타냈으나, 구축 데이터셋은 능선의 저온과 동해안의 고온을 지형을 따라 구분했다. 다만 그림 11의 구축 데이터셋은 관측소를 포함하여 구축한 값이므로, 표 3에서는 이 일대 관측소 5곳을 제외하고 다시 구축한 값을 관측과 비교했다. 평창, 대관령, 성산의 관측 기온은 −10.8, −10.4, −6.5 ℃로 4.3 ℃의 차이가 있었으나, 같은 격자에 속한 ERA5에서는 모두 −6.9 ℃였다. 구축 데이터셋은 이 관측 없이도 세 곳을 −9.3, −8.5, −5.4 ℃로 구분했다. 기온 차이가 컸던 다른 사례에서도 결과는 같았다.

표 3에서 두 데이터의 오차가 가장 컸던 곳은 산지의 평창과 대관령이었다. 이러한 경향이 전국의 산지에서도 나타나는지 확인하기 위해, 관측소를 해발고도 구간으로 나누어 두 데이터의 평균제곱근오차를 비교했다. 그림 12는 그 결과이며, 구축 데이터셋은 각 관측소를 제외하고 추정한 값이다.

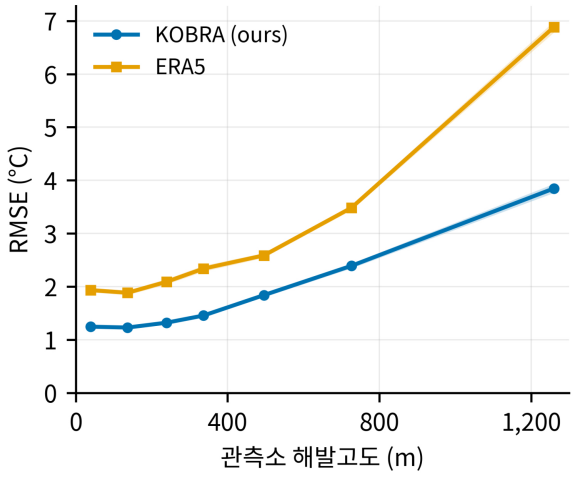

그림 12. 해발고도에 따른 ERA5와 KOBRA의 기온 평균제곱근오차
Fig. 12. Air temperature RMSE of ERA5 and KOBRA by elevation

그림 12에서 해발 400 m 미만의 평균제곱근오차는 구축 데이터셋 1.2~1.5 ℃, ERA5 1.9~2.3 ℃였다. 그러나 900 m 이상에서는 ERA5가 6.89 ℃, 구축 데이터셋이 3.85 ℃였다. ERA5의 값은 격자 평균 고도의 기온이므로 산 위의 관측소에서 오차가 커지는 반면, 구축 데이터셋은 고지대에서도 해발고도에 따른 기온 변화를 반영했다.

이처럼 구축 데이터셋은 ERA5의 격자 안에서 평균되는 산지와 해안의 기온 차이를 해당 지점의 관측 없이도 나타냈으며, 이는 전국의 산지에서도 확인되었다. 따라서 구축 데이터셋은 격자 하나 안의 지형 차이를 학습해야 하는 국지 기상 연구의 학습 데이터로 활용할 수 있다. 다만 고지대에서는 구축 데이터셋도 기온을 관측보다 다소 높게 추정하므로, 고산 지역을 대상으로 할 때는 이를 고려해야 한다.

4.3. 다운스트림 태스크 적용 실험

4.3.1 실험 설정

표 4. U-Net 기반 초단기 예측 모델의 학습 설정
Table 4. Training settings of the U-Net-based nowcasting model

항목	설정
Input	과거 6시간의 8개 변수
Output	1~6시간 후의 기온·풍속·1시간 강수
Model	U-Net (3 levels)
Train / validation / test	2020–2023 / 2024 / 2025
Loss	MAE
Optimizer	AdamW (learning rate 10^{-3}, weight decay 10^{-4})
Batch size	16
Learning-rate schedule	Cosine decay
Stopping	Max. 15 epochs, early stopping (patience 3)
Hardware	1 set NVIDIA GeForce RTX 3090 GPU

구축 데이터셋이 딥러닝 학습 데이터로 활용될 수 있는지 확인하기 위해, 데이터셋만으로 초단기 기상 예측 모델을 학습하고 그 예측을 평가했다. 초단기 기상 예측은 현재까지의 기상으로부터 수 시간 후의 기상을 예측하는 문제로, 모델이 데이터셋에 담긴 시간에 따른 기상의 변화를 학습해야 한다.

학습 데이터로는 플랫폼에서 추출한 5 km 데이터셋을 별도의 전처리 없이 사용했으며, 이 가운데 2020~2023년으로 모델을 학습했다. 모델은 격자를 입력받아 같은 크기의 격자를 출력하는 합성곱 신경망인 U-Net[27]으로, 과거 6시간의 기온, 이슬점, 상대습도, 바람의 동서·남북 성분, 풍속, 해면기압, 1시간 강수와 해발고도를 입력받아 1~6시간 후의 기온, 풍속, 1시간 강수를 출력한다. 학습 설정은 표 4와 같다.

4.3.2 예측 결과

학습한 모델은 학습에 사용하지 않은 2025년에 대해 09시에 시작하는 예측을 수행하여, 04시부터 09시까지의

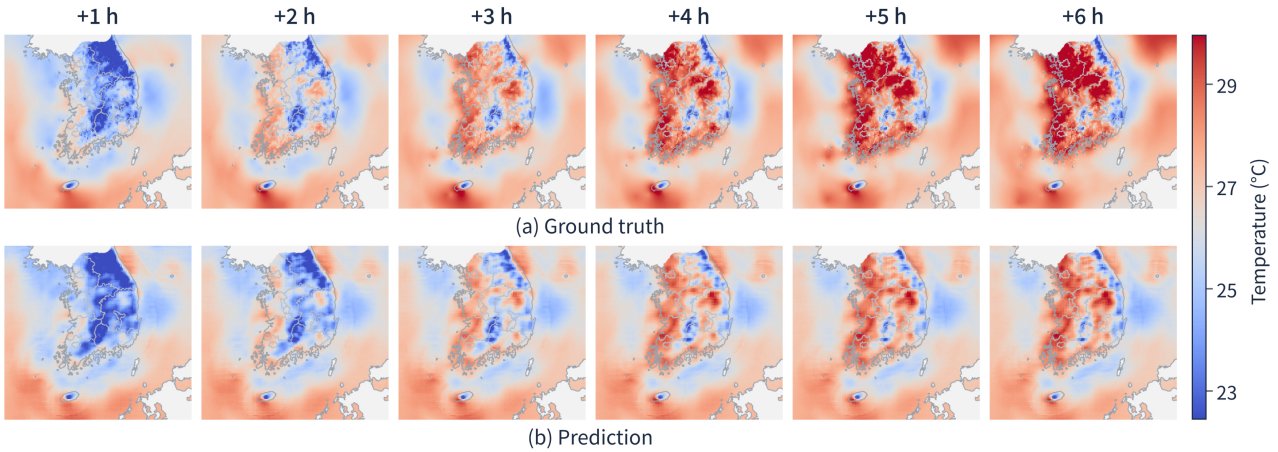

그림 13. KOBRA 데이터셋으로 학습한 U-Net의 1~6시간 기온 예측: (a) 실제값, (b) 예측값

Fig. 13. 1-6 h air temperature prediction by U-Net trained on the KOBRA dataset: (a) ground truth, (b) prediction

데이터로 10시부터 15시까지의 기상을 예측했다. 예측값은 실제 기상과 비교하기 위해 지상 관측소 위치에서 관측값과 비교했으며, 오차는 평균제곱근오차로 평가했다.

표 5. 관측소 관측값으로 평가한 예측 시간별 평균제곱근오차: U-Net, 지속성 예측, 기후값 예측

Table 5. RMSE by lead time evaluated against station observations: U-Net, persistence forecast, and climatological forecast

변수	예측 시간	U-Net	Persistence	Climatology
기온 (°C)	1 h	1.32	1.54	3.86
	2 h	1.49	2.64	3.95
	3 h	1.69	3.47	4.08
	4 h	1.88	4.06	4.17
	5 h	2.08	4.44	4.24
	6 h	2.27	4.62	4.28
풍속 (m/s)	1 h	1.16	0.93	1.57
	2 h	1.23	1.19	1.58
	3 h	1.29	1.38	1.58
	4 h	1.35	1.53	1.58
	5 h	1.40	1.63	1.58
	6 h	1.44	1.69	1.58
1시간 강수 (mm)	1 h	0.92	1.06	1.08
	2 h	1.03	1.29	1.15
	3 h	1.15	1.41	1.23
	4 h	1.19	1.47	1.23
	5 h	1.23	1.52	1.26
	6 h	1.28	1.60	1.29

다만 오차의 크기만으로는 모델이 데이터셋으로부터 기상의 변화를 학습했는지 판단하기 어려우므로, 시작 시각의 값이 그대로 유지된다고 보는 지속성 예측(persistence)[28]과 같은 월·시각의 학습 기간 평균을 사용하는 기후값 예측(climatology)의 오차를 함께 구하여 비교했다. 두 예측은 학습 없이 얻을 수 있으므로, 학습한 모델은 이보다 오차가 작아야 한다.

표 5의 결과에서 기온과 1시간 강수는 모든 예측 시간에서 U-Net의 오차가 가장 낮았으며, 기온의 6시간 예측 오차는 2.27 °C로 지속성 예측의 4.62 °C보다 51% 낮았다. 풍속은 1~2시간 예측에서 지속성 예측의 오차가 더 작았고, 3시간 예측부터 U-Net이 가장 정확했다. 이는 풍속의 변동 중 하루 주기로 설명되는 비율이 19%로 기온의 89%보다 낮아, 짧은 시간의 변화를 학습하기 어렵기 때문이다.

그림 13은 2025년 9월 11일 09시에 시작한 기온 예측 사례이다. U-Net은 오전부터 한낮까지 내륙의 기온 상승을 재현했으나, 4시간 이후에는 고온 구역을 약하게 예측했다.

이처럼 구축 데이터셋만으로 학습한 모델은 실제 관측에 대해서도 대부분의 경우 두 기준 예측보다 정확했으며, 기온의 6시간 예측에서는 지속성 예측의 오차를 절반으로 줄였다. 따라서 구축 데이터셋은 별도의 전처리 없이 딥러닝 모델의 학습 데이터로 활용할 수 있다. 다만 풍속처럼 짧은 시간에 불규칙하게 변하는 변수는 1~2시간 예측에서 학습의 효과가 작으므로, 이러한 변수의 단기 예측을 다룰 때는 이를 고려해야 한다.

V. 결론

본 논문은 ERA5의 0.25° 격자에서 평균되는 대한민국의 국지 기상을 학습할 수 있도록, 기상청의 지상·해양·고층 관측을 변수의 특성에 맞게 보간하여 2006~2025년 1시간 단위의 5 km·500 m 격자 데이터셋으로 구축했다. 이 데이터셋을 필요한 범위만 추출하여 사용할 수 있도록 플랫폼 KOBRA를 제안했다.

구축한 데이터셋은 세 가지 실험으로 검증했다. 구축 데이터셋은 관측소가 없는 위치에서도 정확했다. k-fold 교차검증에서 네 변수 모두 최근접 이웃법보다 정확했고 기온의 평균제곱근오차는 역거리 가중법보다 10% 낮았으며, 이 결과는 관측소를 30%까지 제외해도 유지되었다. 또한 ERA5의 격자 안에서 평균되는 국지 기상을 담고 있었다. 태백산맥 산지와 해안의 기온 차이를 해당 지점의 관측 없이도 구분했고, 해발 900 m 이상 관측소의 기온 평균제곱근오차는 3.85 °C로 ERA5의 6.89 °C보다 44% 낮았다. 나아가 별도의 전처리 없이 딥러닝 모델의 학습 데이터로 활용할 수 있었다. 플랫폼에서 추출한 데이터로 학습한 초단기 예측 모델은 실제 관측에 대해 지속성 예측과 기후값 예측보다 정확했으며, 6시간 기온 예측의 오차는 지속성 예측보다 51% 낮았다.

이러한 결과는 연구 목적에 따라 데이터셋의 적합성을 판단하는 기준이 된다. 기온은 해발고도에 따른 변화를 반영하므로 지형의 영향을 받는 국지 기상 연구에 적합하며, 상대습도, 풍속, 1시간 강수는 역거리 가중법과 비슷한 수준이므로 이들 변수의 국지적 차이를 다루는 연구에서는 이를 고려해야 한다. 고지대의 기온은 관측보다 다소 높게 추정되고 풍속은 2시간 이내의 예측에서 지속성 예측이 더 정확했으므로, 고산 지역과 풍속의 단기 예측을 다룰 때는 이에 유의해야 한다. 이러한 기준에 따라 KOBRA는 기상 예측을 비롯하여 기상의 영향을 받는 여러 분야의 다운스트림 태스크에 공통 학습 데이터로 활용될 수 있으며, 여러 연구가 같은 데이터셋을 사용하면 데이터셋의 차이 없이 모델의 성능을 비교할 수 있다.

향후에는 같은 절차로 다른 공간 해상도의 데이터셋을 구축하고, 위성·레이더처럼 격자로 제공되는 관측을 같은 체계에 추가하여 형태가 다른 데이터를 함께 학습하는 멀티모달 학습으로 활용을 확장할 계획이다. 또한 농업·에너지·교통과 같이 기상 정보가 필요한 다양한 분야에 데이터셋을 적용하여, 기상 예측 외의 다운스트림 태스크에서도 활용 가능성을 확인하고자 한다.

References

〔1〕 P. Bauer, A. Thorpe, and G. Brunet, "The quiet revolution of numerical weather prediction," *Nature*, vol. 525, no. 7567, pp. 47-55, Sep. 2015. (https://doi.org/10.1038/nature14956)

〔2〕 M. G. Schultz et al., "Can deep learning beat numerical weather prediction?," *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, vol. 379, no. 2194, art. no. 20200097, Apr. 2021. (https://doi.org/10.1098/rsta.2020.0097)

〔3〕 L. Olivetti and G. Messori, "Advances and prospects of deep learning for medium-range extreme weather forecasting," *Geoscientific Model Development*, vol. 17, no. 6, pp. 2347-2358, Mar. 2024. (https://doi.org/10.5194/gmd-17-2347-2024)

〔4〕 H. Hersbach et al., "The ERA5 global reanalysis," *Quarterly Journal of the Royal Meteorological Society*, vol. 146, no. 730, pp. 1999-2049, Jul. 2020. (https://doi.org/10.1002/qj.3803)

〔5〕 H. Song and D. Youn, "Comparisons of 1-hour-averaged surface temperatures from high-resolution reanalysis data and surface observations," *Journal of the Korean Earth Science Society*, vol. 41, no. 2, pp. 95-110, Apr. 2020. (https://doi.org/10.5467/JKESS.2020.41.2.95)

〔6〕 S.-Y. Chung, M.-S. Jung, Y.-I. Jo, and J.-H. Lee, "Construction of a 3D wind speed and direction dataset based on ASOS for time-series deep learning model training," in *Proc. 58th Fall Conf. Korea Institute of Information and Communication Engineering (KIICE)*, vol. 29, no. 2, pp. 87-90, Busan, Korea, Oct. 2025.

〔7〕 S.-Y. Chung, M.-S. Jung, Y.-I. Jo, and J.-H. Lee, "ASOS-based wind gust prediction model using deep learning," in *Proc. Korea Software Congress (KSC 2025)*, pp. 140-142, Yeosu, Korea, Dec. 2025.

〔8〕 S.-Y. Chung, M.-S. Jung, and J.-H. Lee, "A Transformer-based wide-area weather prediction model for weather-aware mission planning," in *Proc. 2026 International Symposium on Intelligent Signal Processing and Communication Systems (ISPACS 2026)*, Busan, Korea, Oct. 2026.

〔9〕 J.-C. Park and M.-K. Kim, "Comparison of precipitation distributions in precipitation data sets representing 1 km spatial resolution over South Korea produced by PRISM, IDW, and cokriging," *Journal of the Korean Association of Geographic Information Studies*, vol. 16, no. 3, pp. 147-163, Sep. 2013. (https://doi.org/10.11108/kagis.2013.16.3.147)

〔10〕 J. Pathak et al., "FourCastNet: A global data-driven

high-resolution weather model using adaptive Fourier neural operators," *arXiv preprint arXiv:2202.11214*, Feb. 2022. (https://doi.org/10.48550/arXiv.2202.11214)

〔11〕 K. Bi, L. Xie, H. Zhang, X. Chen, X. Gu, and Q. Tian, "Accurate medium-range global weather forecasting with 3D neural networks," *Nature*, vol. 619, no. 7970, pp. 533-538, Jul. 2023. (https://doi.org/10.1038/s41586-023-06185-3)

〔12〕 R. Lam et al., "Learning skillful medium-range global weather forecasting," *Science*, vol. 382, no. 6677, pp. 1416-1421, Dec. 2023. (https://doi.org/10.1126/science.adi2336)

〔13〕 D. Han, J. Im, Y. Shin, and J. Lee, "Key factors for quantitative precipitation nowcasting using ground weather radar data based on deep learning," *Geoscientific Model Development*, vol. 16, no. 20, pp. 5895-5914, Oct. 2023. (https://doi.org/10.5194/gmd-16-5895-2023)

〔14〕 W. Kim, C.-H. Jeong, and S. Kim, "Improvements in deep learning-based precipitation nowcasting using major atmospheric factors with radar rain rate," *Computers & Geosciences*, vol. 184, art. no. 105529, Mar. 2024. (https://doi.org/10.1016/j.cageo.2024.105529)

〔15〕 D. Shepard, "A two-dimensional interpolation function for irregularly-spaced data," in *Proc. 23rd ACM National Conference*, pp. 517-524, USA, 1968. (https://doi.org/10.1145/800186.810616)

〔16〕 M. A. Oliver and R. Webster, "Kriging: A method of interpolation for geographical information systems," *International Journal of Geographical Information Systems*, vol. 4, no. 3, pp. 313-332, Jul. 1990. (https://doi.org/10.1080/02693799008941549)

〔17〕 T. Hengl, G. B. M. Heuvelink, and D. G. Rossiter, "About regression-kriging: From equations to case studies," *Computers & Geosciences*, vol. 33, no. 10, pp. 1301-1315, Oct. 2007. (https://doi.org/10.1016/j.cageo.2007.05.001)

〔18〕 H.-L. Cho and J.-C. Jeong, "Application of spatial interpolation to rainfall data," *The Journal of GIS Association of Korea*, vol. 14, no. 1, pp. 29-41, Apr. 2006.

〔19〕 J.-W. Eo, Y.-Y. Kim, S.-Y. Lim, and S.-C. Yu, "Reliability evaluation of spatial interpolation in terms of the maximum instantaneous wind speed at unobserved areas using ASOS in Korea," *Journal of Agricultural, Life and Environmental Sciences*, vol. 36, no. 3, pp. 232-242, Sep. 2024.

〔20〕 J.-S. Lee, Y. H. Lee, J.-C. Ha, and H.-C. Lee, "Objective analysis of temperature using the elevation-dependent weighting function," *Atmosphere*, vol. 22, no. 2, pp. 233-243, Jun. 2012.

〔21〕 N.-W. Park and D.-H. Jang, "Mapping of temperature and rainfall using DEM and multivariate kriging," *Journal of the Korean Geographical Society*, vol. 43, no. 6, pp. 1002-1015, Dec. 2008.

〔22〕 T. Kim, N. Ho, D. Kim, and S.-Y. Yun, "Benchmark dataset for precipitation forecasting by post-processing the numerical weather prediction," *arXiv preprint arXiv:2206.15241*, Jun. 2022. (https://doi.org/10.48550/arXiv.2206.15241)

〔23〕 J. R. Holton and G. J. Hakim, *An Introduction to Dynamic Meteorology*, 5th Ed., Academic Press, 2013.

〔24〕 C. Buontempo et al., "The Copernicus Climate Change Service: Climate science in action," *Bulletin of the American Meteorological Society*, vol. 103, no. 12, pp. E2669-E2687, Dec. 2022. (https://doi.org/10.1175/BAMS-D-21-0315.1)

〔25〕 N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore, "Google Earth Engine: Planetary-scale geospatial analysis for everyone," *Remote Sensing of Environment*, vol. 202, pp. 18-27, Dec. 2017. (https://doi.org/10.1016/j.rse.2017.06.031)

〔26〕 H. E. Beck et al., "MSWX: Global 3-hourly 0.1° bias-corrected meteorological data including near-real-time updates and forecast ensembles," *Bulletin of the American Meteorological Society*, vol. 103, no. 3, pp. E710-E732, Mar. 2022. (https://doi.org/10.1175/BAMS-D-21-0145.1)

〔27〕 O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation," in *Proc. Medical Image Computing and Computer-Assisted Intervention (MICCAI 2015)*, Lecture Notes in Computer Science, vol. 9351, pp. 234-241, Munich, Germany, Oct. 2015. (https://doi.org/10.1007/978-3-319-24574-4_28)

〔28〕 G. Ayzel, T. Scheffer, and M. Heistermann, "RainNet v1.0: A convolutional neural network for radar-based precipitation nowcasting," *Geoscientific Model Development*, vol. 13, no. 6, pp. 2631-2644, Jun. 2020. (https://doi.org/10.5194/gmd-13-2631-2020)